

Predição de evasão estudantil no curso de
Sistemas de Informação da UFVJM
Uma Análise por Ciência de Dados e Aprendizado de Máquina

Josiney Maфра Barbosa Junior

Orientador: Prof. Dr. Alessandro Vivas
Universidade Federal dos Vales do Jequitinhonha e Mucuri

2026

- Evasão na grande área de **Computação** no Brasil ultrapassa **60%**.
- Fenômeno **multifatorial**: condições acadêmicas, socioeconômicas, institucionais e pessoais.
- Custos em três níveis: **estudante**, **universidade** e **sociedade**.

Oportunidade analítica

Cada estudante deixa um **rastro digital** nos sistemas institucionais (matrículas, notas, frequência).

A Ciência de Dados permite **antecipar** o desfecho e apoiar um **Sistema de Alerta Precoce (SAP)**.

Objetivo geral

Aplicar técnicas de **Ciência de Dados e Aprendizado de Máquina** para **identificar e analisar os fatores preditivos da evasão e da retenção prolongada** dos estudantes do curso de Sistemas de Informação da UFVJM.

Objetivos específicos


- ❶ **Explorar** e preparar os dados, garantindo qualidade e consistência.
- ❷ **Modelar** a evasão (Regressão Logística, *Random Forest*, *XGBoost*) e a dimensão temporal (Kaplan-Meier e Cox).
- ❸ **Avaliar** o desempenho com métricas sensíveis ao desbalanceamento e identificar os atributos de maior impacto.

Produto final: subsídio para um **Sistema de Alerta Precoce**.

- H1** A **reprovação por frequência** é um dos preditores mais relevantes da evasão.
- H2** O **ciclo de Matemática** (MAT001–MAT003) é o filtro estrutural dominante, acima das disciplinas iniciais de Computação.
- H3** O **CRA** dos primeiros semestres é indicador precoce de risco.
- H4** O **tempo prolongado sem progressão** curricular eleva o risco de evasão.
- H5** *Ensembles de árvore* (RF, XGBoost) superam a Regressão Logística em métricas sensíveis ao desbalanceamento.

Cada hipótese é retomada nos **Resultados** com veredito de confirmação.

- Abordagem quantitativa, orientada a dados.
- Organizada nas 6 fases do CRISP-DM.
- Cada fase materializada em artefatos: *src/*, *notebooks* e painel *Streamlit*.



Base institucional (SIE/UFVJM) — 3 tabelas integradas:

- 1.119 estudantes
- 37.925 registros disciplinares

Decisões-chave

- Recorte: ingressantes até 2024/1.
- Exclusão de COM038 (TCC).
- Tabela analítica: **uma linha por aluno.**

Features ancoradas nas hipóteses

CRA e CRA médio, taxa de aprovação, reprovações por nota/frequência, tentativas em MAT001–003, trancamentos, variância das notas.

Ressalva metodológica

As *features* são **cumulativas**.

Duas frentes complementares

- **Sobrevivência** (Kaplan-Meier + Cox): *quando* a evasão ocorre.
- **Classificação** (LogReg, RF, XGBoost): *quem* tende a evadir.

Avaliação

- **F1**, *recall*, **precisão**, **AUC** (acurácia engana em dados desbalanceados).
- Validação cruzada estratificada (5 *folds*) + *hold-out*.
- Interpretabilidade via **SHAP**.
- Reprodutibilidade: `random_state = 42`.



- 587 **Evadidos** (52,5%), 260 **Concluintes** (23,2%), 271 **Ativos** (24,2%).

- Taxa de evasão (desfecho consolidado):

$$\frac{587}{587 + 260} = 69,3\%$$

- Compatível com a literatura (>60% em Computação).


Cautela: coortes recentes sofrem censura à direita.




- Concluintes: mediana de CRA ≈ 73 .
- Evadidos: mediana ≈ 45 .
- Ativos: comportamento próximo ao dos concluintes.

Leitura

Primeira evidência descritiva forte a favor de H3.




Top 15 disciplinas por taxa de reprovação



- Ciclo de Matemática nas 3 primeiras posições: **MAT003 63%**, **MAT002 57%**, **MAT001 53%**.
- COM001 em 5^o (48%) e COM006 em 6^o (45%).
- MAT001: maior evasão subsequente (52%).

Veredito

H2 confirmada: Matemática supera Computação.



- **11%** evadem já no 1º semestre; $\sim 46\%$ até o 9º (tempo regular).
- Mediana de permanência $\approx$ **11 semestres**.
- Estratificação por CRA: **log-rank**
 $p < 0,001$.
- Modelo de Cox: índice de concordância **0,913**.

HR < 1 das reprovações cumulativas (viés de seleção).

Modelo	F1	AUC	Recall	Precisão
Regressão Logística	0,943	0,976	0,908	0,980
<i>Random Forest</i>	0,953	0,981	0,944	0,962
<i>XGBoost</i>	0,957	0,982	0,947	0,967


*

Médias na validação cruzada estratificada (5 *folds*).

- *Hold-out*: RF melhor F1 (**0,966**); *recall* RF/XGB = 0,949.
- *Recall* importa num SAP: falso negativo custa mais.

Veredito

H5 confirmada: *ensembles* superam o *baseline* em F1 e *recall*.



- Topo: taxa_aprovacao, cra_medio, reprovacoes_nota, cra.
- tentativas_mat002/003 em 4^o–6^o ⇒ H2 em nível individual.
- reprovacoes_frequencia em 8^o ⇒ H1 parcial.
- tipoiingresso_Vestibular em 12^o ⇒ discussão de viés algorítmico.

Hipótese	Veredito
H1 Reprovação por frequência	Parcial
H2 Ciclo de Matemática como filtro dominante	Confirmada
H3 CRA como indicador precoce	Confirmada
H4 Tempo sem progressão	Parcial
H5 <i>Ensembles</i> de árvore superam <i>baseline</i>	Confirmada

Painel interativo em *Streamlit*

- Visão temporal da evasão por coorte.
- Mapeamento das disciplinas-gargalo.
- **Semáforo de risco individual** com explicação.

Cada alerta vem com **justificativa quantificada**. A decisão final é da **coordenação**.

Enfrenta o “problema da última milha”

Traduz o rigor técnico em **instrumento acionável** pela gestão.

Contribuições

- Painel acionável (SAP).

Limitação central

Modelo é **diagnóstico retrospectivo**, não predição prospectiva pura (*features* cumulativas).

Obrigado!

Josiney Mafra Barbosa Junior

Orientador: Prof. Dr. Alessandro Vivas

Universidade Federal dos Vales do Jequitinhonha e Mucuri

À disposição para perguntas.