

Uso de Redes Neurais Artificiais para Diagnóstico de Doenças Cardíacas

Lucas dos Santos Martins

Orientador: Prof. Dr. Leonardo Lana de Carvalho

Banca: Prof. André Luiz Covre Prof. Áthila Rocha Trindade

Universidade Federal dos Vales do Jequitinhonha e Mucuri

2026

- Doenças cardiovasculares: **principal causa de morte no mundo**
- Diagnóstico precoce é fundamental, mas **nem sempre disponível a tempo**

Papel das Redes Neurais

Auxiliar o médico, não substituir o julgamento clínico, oferecendo de forma rápida e a qualquer momento uma **análise baseada nos dados do paciente**.

Impacto prático

Com base no resultado, o médico pode **priorizar investigações** e ficar mais atento a casos de risco.

Objetivo

Objetivo Geral

Desenvolver e comparar modelos de **redes neurais artificiais** para a previsão de doenças cardíacas em dois contextos clínicos distintos.

Modelos implementados:

- **ADALINE Logística**: neurônio único
- **Perceptron Multicamadas (MLP)**: rede multicamadas

Cada modelo em **duas versões**:
implementação manual
vs biblioteca (Scikit-learn)

Questões respondidas:

- A complexidade extra do Multicamadas traz **ganho real**?
- As implementações manuais **reproduzem** os resultados da biblioteca?
- Qual modelo é mais **cl clinicamente seguro** (menos falsos negativos)?
- A **binarização prévia** dos dados traz ganhos para os modelos ou não?

Bancos de Dados

Banco 1 — Heart Disease Dataset

- **918 pacientes** — 11 variáveis clínicas (508 doentes | 410 saudáveis)
- Idade, pressão arterial, colesterol, tipo de dor torácica, eletrocardiograma (ECG)...
- **Alvo:** presença de doença cardíaca (0/1)
- Divisão **70/30**:
642 treino | 276 teste

Banco 2 — Heart Failure Clinical Records

- **299 pacientes** — 12 variáveis (96 óbitos | 203 sobreviventes)
- Idade, tempo de acompanhamento, anemia, diabetes, hipertensão...
- **Alvo:** óbito durante acompanhamento (0/1)
- Divisão **70/30**:
209 treino | 90 teste

Contextos distintos: **diagnóstico de doença cardíaca** vs **prognóstico de insuficiência cardíaca**

Transformações aplicadas (Banco 1):

- **Separação em colunas binárias:** tipo de dor torácica
ATA, NAP, ASY, TA $\rightarrow$ 4 colunas binárias
- **Mapeamento binário:**
Sexo (M=1 / F=0)
Angina (Y=1 / N=0)
- **Binarização por faixas clínicas:**
Idade, colesterol, pressão arterial...

Divisão treino/teste:

- Proporção **70/30**
- Preserva proporção de casos positivos em cada partição

O que é o ADALINE Logístico?

- Modelo de **neurônio único**
- Aplica a função **sigmoide** na saída para classificação binária, retornando uma **probabilidade** entre 0 e 1

Por que usar o ADALINE Logístico?

- **Referência simples:** se já performa bem, questiona-se o ganho real do Multicamadas
- Computacionalmente leve

O que é o Multicamadas?

- Rede com **pelo menos uma camada oculta**
- Aprende relações **não-lineares** entre variáveis
- Nossa implementação:
10 neurônios ocultos
+ 1 neurônio de saída (sigmoide)

Por que usar o Multicamadas?

- Responde à pergunta central: a **complexidade extra traz ganho real** em dados clínicos?
- Representa o próximo nível acima do ADALINE Logístico

Configurações de Experimento

Épocas:

- Quantas vezes o modelo percorre os dados de treino
- Poucas épocas → modelo **não aprende o suficiente**
- Épocas demais → modelo **memoriza** os dados e perde capacidade de generalizar (*overfitting*)

Taxa de aprendizado:

- Controla o **tamanho do passo** de cada ajuste
- Taxa alta → aprende rápido, mas de forma **grosseira**
- Taxa baixa → ajustes mais **finos**, mas exige mais tempo

Três configurações por modelo

Config.	Épocas	Taxa
C1	500	0,01
C2	1.000	0,001
C3	3.000	0,0001

- **C1** — rápido, ajustes grosseiros
- **C2** — equilíbrio velocidade/precisão
- **C3** — ajustes finos, risco de *overfitting*

Resultados — Banco 1: Heart Disease

918 pacientes: 508 doentes | 410 saudáveis

Modelo	C1	C2	C3	FN mín.
Adaline Sem Biblioteca	85,87% / 28 FN	86,23% / 21 FN	86,96% / 20 FN	20 (C3)
Adaline Com Biblioteca	85,87% / 21 FN	86,23% / 21 FN	86,23% / 21 FN	21 (Todos)
Multicamadas Sem Biblioteca	82,97% / 27 FN	86,23% / 16 FN	87,68% / 15 FN	15 (C3)
Multicamadas Com Biblioteca	87,32% / 18 FN	88,04% / 20 FN	82,61% / 35 FN	18 (C1)

Maior acurácia

Multicamadas Com Biblioteca C2: **88,04%**


Melhor clinicamente

Multicamadas Sem Biblioteca C3: **15 FN**

Melhor modelo geral: Multicamadas Sem Biblioteca C3 — melhor equilíbrio entre acurácia (87,68%) e FN mínimo (15)


Banco 1 — Visualização dos Resultados

Acurácia por Configuração (%)



↑ maior acurácia = melhor desempenho geral

Falsos Negativos por Configuração



↓ menos FN = melhor clinicamente

Resultados — Banco 2: Heart Failure

299 pacientes: 96 óbitos / 203 sobreviventes

Modelo	C1	C2	C3	FN mín.
Adaline Sem Biblioteca	68,89% / 17 FN	72,22% / 17 FN	75,56% / 16 FN	16 (C3)
Adaline Com Biblioteca (=)	68,89% / 17 FN	68,89% / 17 FN	68,89% / 17 FN	17 (=)
Multicamadas Sem Biblioteca	78,89% / 9 FN	75,56% / 14 FN	71,11% / 23 FN	9 (C1)
Multicamadas Com Biblioteca	73,33% / 18 FN	68,89% / 17 FN	63,33% / 8 FN*	17 (C2)

*8 FN com 63,3% de acurácia: modelo classifica quase todos como doentes — clinicamente não confiável

Maior acurácia

Multicamadas Sem Biblioteca C1: **78,89%**


Melhor clinicamente

Multicamadas Sem Biblioteca C1: **9 FN**

Melhor modelo geral: Multicamadas Sem Biblioteca C1 — melhor equilíbrio entre acurácia (78,89%) e FN mínimo (9)

Banco 2 — Visualização dos Resultados


Acurácia por Configuração (%)



ADALINE SB ADALINE CB
Multicamadas SB Multicamadas CB

Overfitting visível: Multicamadas SB e Multicamadas CB pioram progressivamente com mais épocas

Falsos Negativos por Configuração



ADALINE SB ADALINE CB
Multicamadas SB Multicamadas CB

Experimento Complementar: Binarizados vs Contínuos

Hipótese: A binarização favoreceria o ADALINE por simplificar o espaço de decisão.

Banco 1 — resultado próximo

Acurácias similares. A binarização não trouxe ganho significativo, mas também não prejudicou.


Banco 2 — resultado revelador

ADALINE SB subiu de 68,9% para **82,2%**

FN: de 17 para **11**

Multicamadas CB: caiu para **45,6%**
(instável)

Banco 2 — Acurácia: Binarizados vs Contínuos





A hipótese não se confirmou: o ADALINE se beneficiou mais dos dados contínuos neste contexto

Validação: Implementação Manual vs Biblioteca

- **ADALINE SB vs ADALINE CB:**
Resultados praticamente idênticos
- **Multicamadas SB vs Multicamadas CB:**
Divergências maiores

Destaque

Multicamadas SB **superou** o Multicamadas CB em C3 (87,68% vs 82,61%) — implementação manual **competitiva**.



Melhores resultados:

- **Banco 1:** Multicamadas Sem Biblioteca C3 — **melhor modelo geral** (87,68% / 15 FN)
- **Banco 2:** Multicamadas Sem Biblioteca C1 — **melhor equilíbrio** (78,89% / 9 FN)

Conclusões das comparações:

- **Qual modelo?** O Multicamadas superou o ADALINE em ambos os bancos — a complexidade extra **trouxe ganho real**
- **Manual vs Biblioteca?** Implementações manuais produziram resultados **competitivos** e, no Multicamadas C3, até **superiores**
- **Binarizar ou não?** A binarização **não trouxe vantagem**; os dados contínuos favoreceram o ADALINE no Banco 2

Obrigado!

Lucas dos Santos Martins

Orientador: Prof. Dr. Leonardo Lana de Carvalho

Universidade Federal dos Vales do Jequitinhonha e Mucuri

À disposição para perguntas.